

第3章 最佳逼近和最小二乘法

3.1 内积空间中的最佳逼近

3.2 函数的最佳平方逼近

3.3 勒让德多项式和切比雪夫多项式

3.4 曲线（数据）拟合的最小二乘法

3.5 $C[a, b]$ 中最佳一致逼近

基本问题

已知一组测量数据 (x_j, y_j) ($j = 0, 1, \dots, n$)

寻找变量 x, y 之间函数关系的近似表达式。

通过该函数关系的近似表达式计算其它点 x^* 处的函数值。

解决办法 1) 插值法

插值法是一种古老而实用的数值方法，也是函数逼近的重要方法之一。

插值法

构造一个(相对简单的)函数 $y = s(x)$, 通过全部节点,
且


$$s(x_j) = y_j \quad (j = 0, 1, \dots, n)$$

可用 $s(x)$ 求已知点处 $y^* = s(x^*)$.

》由于插值多项式过节点, 若测量数据有误差, 误差保留在插值多项式中, 影响逼近精度, 插值效果不理想。

》测量数据众多时, 高次插值多项式近似程度不稳定, 故缺乏实用价值。

x	x_0	x_1	x_2	x_n
y	y_0	y_1	y_2	y_n



2) 函数的最佳逼近 (从整体角度考虑)

对于函数 $f(x)$, 要求在一个简单函数类 B 中, 寻找一个函数 $s(x) \in B$, 不一定过全部的点 (x_i, y_i) 使得 $s(x)$ 与 $f(x)$ 的 误差在某种度量下达到最小, 这一问题称为最佳逼近问题,

$s(x)$ 称为 $f(x)$ 的 最佳逼近函数.

简单函数类 B 通常为 n 次多项式、有理函数或分段低次多项式等

• 线性（向量）空间：

线性空间（数域 K ）四要素：

非空集合 E ，数域 K 和两种运算：加法与数乘，分别满足如下运算规律

$$+ \quad E \times E \rightarrow E, \begin{cases} x + y = y + x \in E \\ x + (y + z) = (x + y) + z \in E \\ x + 0 = x \\ x + (-x) = 0 \end{cases}$$

$$\cdot \quad K \times E \rightarrow E, \begin{cases} \alpha(\beta x) = (\alpha\beta)x \in E \\ 1 \cdot x = x, 0 \cdot x = 0 \\ (\alpha + \beta)x = \alpha x + \beta x \\ \alpha(x + y) = \alpha x + \alpha y \end{cases}$$

线性相关、无关：

$$x_1, x_2, \dots, x_n \in E, \quad \alpha_1, \alpha_2, \dots, \alpha_n \in K,$$

若 $\alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n = 0$ 当且仅当 $\alpha_1 = \alpha_2 = \dots = \alpha_n = 0$

则称 x_1, x_2, \dots, x_n 线性无关，否则线性相关。

线性空间的基：

$x_1, x_2, \dots, x_n \in E$ ，且 x_1, x_2, \dots, x_n 线性无关，若 $\forall x \in E, \exists \alpha_1, \alpha_2, \dots, \alpha_n \in K$,

$$s.t. \quad x = \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n$$

则称 $\{x_1, x_2, \dots, x_n\}$ 为线性空间 E 的一组（线性无关）基或标架（坐标系），

称 $(\alpha_1, \alpha_2, \dots, \alpha_n)$ 为 x 在基 $\{x_1, x_2, \dots, x_n\}$ 下的坐标；

并称线性空间 E 是 n 维空间，记作 $E = \text{span}\{x_1, x_2, \dots, x_n\}$,

若 E 中有无限多个线性无关的元素，则称其为无限维线性空间。

例如,

R^n , $\forall x = (x_1, x_2, \dots, x_n)^T \in R^n, x = x_1 e_1 + x_2 e_2 + \dots + x_n e_n$,
 $e_i = (0, \dots, 1, \dots, 0)^T$, 第*i*个分量为1, 其它分量为0.

$H_n = \text{span}\{1, x, \dots, x^n\}$ 是*n*+1维线性空间,

$\{1, x, \dots, x^n\}$ 是它的一组线性无关基,

$\forall p(x) \in H_n$, 有 $p(x) = a_0 1 + a_1 x + \dots + a_n x^n$

$C[a, b]$, $(f + g)(x) = f(x) + g(x)$, $C[a, b]$, $(\alpha \cdot f)(x) = \alpha f(x)$

是实数域上的无穷维线性空间

- 范数和赋范线性空间

范数:

$$\|\cdot\|: E \rightarrow R, \begin{cases} \|x\| \geq 0, \|x\| = 0 \Leftrightarrow x = 0, & \text{非负性} \\ \|\alpha x\| = |\alpha| \|x\|, & \text{正齐性} \\ \|x + y\| \leq \|x\| + \|y\|, & \text{三角不等式} \end{cases}$$

赋范线性空间: 线性空间+范数

例1. $R^n \quad \forall x = (x_1, x_2, \dots, x_n)^T \in R^n,$

$$\|x\|_2 = \left(\sum_{i=1}^n x_i^2 \right)^{1/2}$$

欧氏范数

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|$$

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}, p \geq 1$$

$$\|x\|_1 = \sum_{i=1}^n |x_i|$$

例2.

$$C[a, b], \quad \|f(t)\|_{\infty} = \max_{t \in [a, b]} |f(t)|$$

$$\|f(t)\|_1 = \int_a^b |f(t)| dt$$

$$\|f(t)\|_2 = \left(\int_a^b |f(t)|^2 dt \right)^{1/2}$$

Hilbert空间

一、内积空间：线性空间+内积
例：

$$R^n, x = (x_1, \cdots, x_n)^T, y = (y_1, \cdots, y_n)^T \quad (x, y) = \sum_{i=1}^n x_i y_i$$

$$C^n, x = (x_1, \cdots, x_n)^T, y = (y_1, \cdots, y_n)^T \quad (x, y) = \sum_{i=1}^n x_i \bar{y}_i$$

内积 $(\cdot, \cdot) : E \times E \rightarrow C(R)$ 满足：

$$(x, x) \geq 0, (x, x) = 0 \Leftrightarrow x = 0 \quad \text{非负性}$$

$$(x, y) = \overline{(y, x)} \quad \text{共轭对称性}$$

$$(\alpha x, y) = \alpha (x, y)$$

$$(x + y, z) = (x, z) + (y, z)$$

第一变元线性性。

Remarks: 内积关于第二变元满足共轭线性性质:

$$(x, \alpha y) = \overline{(\alpha y, x)} = \overline{\alpha(y, x)} = \bar{\alpha}(x, y)$$

$$(x, y + z) = \overline{(y + z, x)} = \overline{(y, x) + (z, x)} = (x, y) + (x, z)$$

例如,

设 $w_i > 0, i = 1, 2, \dots, n$,

$x = (x_1, \dots, x_n)^T, y = (y_1, \dots, y_n)^T \in C^n$, 定义加权的内积

$$(x, y) = \sum_{i=1}^n w_i x_i \bar{y}_i, \quad (w_1, \dots, w_n) \text{ 称为权重。}$$

$$\text{特例, } w_i = 1, \quad i = 1, 2, \dots, n, \quad (x, y) = \sum_{i=1}^n x_i \bar{y}_i$$

设 $[a, b]$ 为有限或无限区间, 非负函数 $\rho(t)$ 满足:

1. $\int_a^b t^k \rho(t) dt$ 存在且有限, $k = 0, 1, \dots$

2. 对 $[a, b]$ 上的非负连续函数 $g(t)$, 若 $\int_a^b \rho(t) g(t) dt = 0$, 则 $g(t) \equiv 0$
则称 $\rho(t)$ 为 $[a, b]$ 上的权函数。

$$C[a, b], (f(t), g(t)) = \int_a^b \rho(t) f(t) g(t) dt$$

$$\text{特例, } \rho(t) \equiv 1, \quad (f(t), g(t)) = \int_a^b f(t) g(t) dt$$

内积的性质：设 E 是 K 上内积空间

1. 内积满足**Cauchy-Schwarz**不等式： $| (x, y) | \leq (x, x)^{\frac{1}{2}} (y, y)^{\frac{1}{2}}$

证： $\forall x, y \in E, \forall \lambda \in K, (x + \lambda y, x + \lambda y) \geq 0,$

$$(x, x) + \bar{\lambda}(x, y) + \lambda(y, x) + |\lambda|^2 (y, y) \geq 0$$

设 $y \neq 0$ 取 $\lambda = -\frac{(x, y)}{(y, y)}$

$$(x, x) - \frac{|(x, y)|^2}{(y, y)} \geq 0 \Rightarrow |(x, y)|^2 \leq (x, x) \cdot (y, y)$$

$y=0$ 时不等式显然成立。

2. 内积可诱导范数 $\|x\| = \sqrt{(x, x)}$

$$C^n, R^n : x = (x_1, \dots, x_n)^T, y = (y_1, \dots, y_n)^T$$

$$(x, y) = \sum_{i=1}^n w_i x_i \bar{y}_i \rightarrow \|x\| = \sqrt{(x, x)} = \sqrt{\sum_{i=1}^n w_i |x_i|^2}$$

$$\text{特例, } w_i=1, \|x\| = \sqrt{\sum_{i=1}^n |x_i|^2}$$

$$C[a, b], (f(t), g(t)) = \int_a^b \rho(t) f(t) \bar{g}(t) dt \rightarrow \|f(t)\| = \sqrt{\int_a^b \rho(t) |f(t)|^2 dt}$$

$$\text{特例, } \rho(t) \equiv 1, \|f(t)\| = \sqrt{\int_a^b |f(t)|^2 dt}$$

3. 内积（导出的范数满足平行四边形公式：

$$\|x + y\|^2 + \|x - y\|^2 = 2(\|x\|^2 + \|y\|^2)$$

4. 内积关于两个量连续。

正交投影、正交分解的定义

定义 设 M 为内积空间 U 的线性子空间,

$x \in U$, 若 $\exists x_0 \in M, x_1 \in M^\perp$, 使得

$$x = x_0 + x_1 \quad (*)$$

则称 x_0 为 x 在 M 上的正交投影, $(*)$ 式称为 x 关于 M 的正交分解。

正交投影及正交分解的存在唯一性

定理: 设 M 为内积空间 U 中的完备线性子空间, 则 $\forall x \in U$, 必存在唯一的 $x_0 \in M$ 及 $x_1 \in M^\perp$, 使得

$$x = x_0 + x_1$$

函数最佳逼近的理论依据

正交投影的性质（最佳逼近）

性质： 设 U 是内积空间， $M \subset U$ 为线性子空间，若 x_0 为 $x \in U$ 在子空间 $M \subset U$ 上的投影，则

$$\|x - x_0\| = \inf_{y \in M} \|x - y\| \quad (**)$$

而且 x_0 是 M 中使 $(**)$ 成立的唯一点。

($\|x - x_0\| = \inf_{y \in M} \|x - y\|$ 说明 x_0 是 M 中逼近 x 的**最佳元**)

注:

在内积空间中，当逼近的线性子空间是有限维时，线性子空间完备，此时，最佳逼近元与投影是一回事。

在通常的数值逼近中，选取的子空间如正交多项式子空间、三角多项式子空间、有限元子空间、边界元子空间等都是有限维，所以求最佳逼近元的问题实际就是求投影的问题。

子空间的构造不同和范数的选取不同构成了不同的数值逼近方法。

3.1 内积空间中的最佳逼近

一、最佳逼近元的定义

设 U 是内积空间, $M \stackrel{\Delta}{=} \text{span}\{x_1, x_2, \dots, x_n\} = \left\{ \sum_{i=1}^n \alpha_i x_i, \forall \alpha_i \in k \right\}$.

对于 $\forall x \in U$, 找 M 中的元素 $x^* = \sum_{i=1}^n \alpha_i^* x_i$

$$\text{s.t.} \quad \|x - x^*\| = \min_{y \in M} \|x - y\| \leq \left\| x - \sum_{i=1}^n \alpha_i x_i \right\|$$

则称 x^* 是 x 在 M 中的“最佳逼近”元, M 为 U 的逼近子空间。

二、最佳逼近元的求法

基本思想： 内积空间 U , n 维线性子空间 $M = \text{span}\{x_1, x_2, \dots, x_n\}$

因为 M 是完备线性子空间（有限维），由投影定理及投影性质

知投影 $x^* = \sum_{i=1}^n \alpha_i^* x_i \in M$ 就是 x 在 M 中的“最佳逼近”元。

$$x^* \in M, \quad x - x^* \in M^\perp \Rightarrow (x - x^*, x_j) = 0 \quad (j = 1, 2, \dots, n)$$

$$\Rightarrow (x - \sum_{i=1}^n \alpha_i^* x_i, x_j) = 0 \quad (j = 1, 2, \dots, n)$$

$$\Rightarrow (x, x_j) - \sum_{i=1}^n \alpha_i^* (x_i, x_j) = 0$$

$$\Rightarrow \sum_{i=1}^n (x_j, x_i) \cdot \alpha_i^* = (x, x_j) \quad (j = 1, 2, \dots, n)$$

$$\sum_{i=1}^n (x_j, x_i) \cdot \alpha_i^* = (x, x_j) \quad (j=1, 2, \dots, n)$$

写成矩阵形式为

$$\begin{bmatrix} (x_1, x_1) & (x_1, x_2) & \cdots & (x_1, x_n) \\ (x_2, x_1) & (x_2, x_2) & \cdots & (x_2, x_n) \\ \vdots & \vdots & \ddots & \vdots \\ (x_n, x_1) & (x_n, x_2) & \cdots & (x_n, x_n) \end{bmatrix} \begin{bmatrix} \alpha_1^* \\ \alpha_2^* \\ \vdots \\ \alpha_n^* \end{bmatrix} = \begin{bmatrix} (x, x_1) \\ (x, x_2) \\ \vdots \\ (x, x_n) \end{bmatrix}$$

法方程
(或正规方程)

记作 $A\alpha^* = b$

x_1, x_2, \dots, x_n 线性无关, \mathbf{A} 可逆

存在唯一解 $\alpha^* = A^{-1}b$, 得最佳逼近元 $x^* = \sum_{i=1}^n \alpha_i^* x_i$

$$\begin{bmatrix} (x_1, x_1) & (x_1, x_2) & \cdots & (x_1, x_n) \\ (x_2, x_1) & (x_2, x_2) & \cdots & (x_2, x_n) \\ \vdots & \vdots & \ddots & \vdots \\ (x_n, x_1) & (x_n, x_2) & \cdots & (x_n, x_n) \end{bmatrix} \begin{bmatrix} \alpha_1^* \\ \alpha_2^* \\ \vdots \\ \alpha_n^* \end{bmatrix} = \begin{bmatrix} (x, x_1) \\ (x, x_2) \\ \vdots \\ (x, x_n) \end{bmatrix}$$

特别地

- ① 如果 x_1, x_2, \dots, x_n 正交 $\Rightarrow A$ 是对角矩阵, $\alpha_i^* = \frac{(x, x_i)}{(x_i, x_i)}$;
- ② 如果 x_1, x_2, \dots, x_n 规范正交 $\Rightarrow A$ 是单位矩阵, $\alpha_i^* = (x, x_i)$

最佳逼近元 $x^* = \sum_{i=1}^n (x, x_i) x_i$ (广义 Fourier 展开的部分和)

综上：

- (1) 求最佳逼近问题 \Leftrightarrow 解线性方程组 $A\alpha = b$ 。
- (2) 矩阵 A 和 b 主要取决于内积空间中内积的定义，以及线性子空间（即基）的选取。
- (3) 若 x_1, x_2, \dots, x_n 线性无关，解得 $\alpha = A^{-1}b$ 。但解此方程组通常计算量很大，且会使 $Ax = b$ 为病态的（即自变量有很小的扰动时，其解的变化具大）。
- (4) 若 x_1, x_2, \dots, x_n 规范正交，解得 $\alpha = b$ 。此方法计算简单，但要先将线性无关组规范正交化，有时计算量也会很大。

注：通常选出正交基即可

三、最佳逼近的误差估计

设 $\delta = x - x^*$ ，则 $\|\delta\|$ 的大小可表示逼近的程度。

$\|\delta\|$ 的计算取决于该内积空间中范数（即内积）的定义。

因为 $x = x^* + (x - x^*)$, $x^* \in M$, $x - x^* \in M^\perp$,

$$\text{故 } \|x\|^2 = \|x^*\|^2 + \|x - x^*\|^2$$

误差的平方

$$\|\delta\|^2 = \|x - x^*\|^2 = \|x\|^2 - \|x^*\|^2$$

$$\begin{aligned}\|\delta\|^2 &= \|x - x^*\|^2 = (x - x^*, x - x^*) \\ &= (x - x^*, x) - (x - x^*, x^*) \\ &= (x - x^*, x) \\ &= (x, x) - (x^*, x) \\ &= (x, x) - \sum_{i=1}^n \alpha_i^* (x_i, x)\end{aligned}$$

误差

$$\|\delta\| = \|x - x^*\| = \sqrt{\|x\|^2 - \|x^*\|^2}$$

$$\text{或 } \|\delta\| = \sqrt{(x, x) - \sum_{i=1}^n \alpha_i^* (x_i, x)}$$

3.2 连续函数的最佳平方逼近

设子空间为 $M = \text{span}\{\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)\}$,

对于 $\forall f(x) \in C[a, b]$, 求函数 $S^*(x) = \sum_{i=0}^n \alpha_i^* \varphi_i(x) \in M$,

$$\text{s. t.} \quad \|f(x) - S^*(x)\|_2 = \min_{S(x) \in M} \|f(x) - S(x)\|_2$$

$$\text{即} \int_a^b p(x)[f(x) - S^*(x)]^2 dx = \min_{S(x) \in M} \int_a^b p(x)[f(x) - S(x)]^2 dx$$

$$\text{其中} S(x) = \sum_{i=0}^n \alpha_i \varphi_i(x) \in M,$$

称 $S^*(x)$ 为 $f(x)$ 在 M 中的最佳平方逼近。

特别地：若线性子空间 $M = \text{span}\{1, x, x^2, \dots, x^n\}$,

则称 $s^*(x)$ 为 $f(x)$ 在 M 中的 n 次最佳平方逼近多项式。

最佳逼近元 $S^*(x)$ 求法

由投影定理知, $S^*(x) = \sum_{i=0}^n \alpha_i^* \varphi_i(x)$ 存在且唯一, 系数 α_i^* 满足法方程

解法方程

$$\begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{bmatrix} \begin{bmatrix} \alpha_0^* \\ \alpha_1^* \\ \vdots \\ \alpha_n^* \end{bmatrix} = \begin{bmatrix} (f, \varphi_0) \\ (f, \varphi_1) \\ \vdots \\ (f, \varphi_n) \end{bmatrix}$$

其中 $(\varphi_i, \varphi_j) = \int_a^b p(x) \varphi_i(x) \varphi_j(x) dx$, $(f, \varphi_j) = \int_a^b p(x) f(x) \varphi_j(x) dx$

故 $S^*(x) = \sum_{i=0}^n \alpha_i^* \varphi_i(x)$ 为所要求的最佳逼近元。

均方误差 $\|\delta\|_2 = \|f - s^*\|_2 = \sqrt{(f, f) - \sum_{i=0}^n \alpha_i^* (f, \varphi_i)}$

例1 求区间 $[-1, 1]$ 上函数 $f(x) = |x|$ 在 $M = \text{span}\{1, x^2, x^4\}$ 中的**最佳平方逼近多项式**及均方误差。

解： 记 $\varphi_0(x) = 1$, $\varphi_1(x) = x^2$, $\varphi_2(x) = x^4$, $p(x) = 1$

计算得 $(\varphi_0, \varphi_0) = 2$, $(\varphi_0, \varphi_1) = 2/3$, $(\varphi_0, \varphi_2) = 2/5$,

$(\varphi_1, \varphi_1) = 2/5$, $(\varphi_1, \varphi_2) = 2/7$, $(\varphi_2, \varphi_2) = 2/9$,

$(f, \varphi_0) = 1$, $(f, \varphi_1) = 1/2$, $(f, \varphi_2) = 1/3$ 。

故法方程为

$$\begin{bmatrix} 2 & 2/3 & 2/5 \\ 2/3 & 2/5 & 2/7 \\ 2/5 & 2/7 & 2/9 \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1/2 \\ 1/3 \end{bmatrix}$$

解得

$$\alpha_0^* = \frac{15}{128} \approx 0.1171875, \quad \alpha_1^* = \frac{105}{64} \approx 1.640625, \quad \alpha_2^* = -\frac{105}{128} \approx -0.8203125$$

$\therefore f(x) = |x|$ 的最佳平方逼近为

$$s^*(x) = 0.1171875 + 1.640625x^2 - 0.8203125x^4$$

误差 $\|\delta\|_2 = \sqrt{(f, f) - \sum_{i=0}^2 a_i^*(f, \varphi_i)} \approx 0.05119$ 。

例2 求 $[0,1]$ 上函数 $f(x) = e^x$ 的一次最佳平方逼近多项式。

分析：最佳平方逼近 \Rightarrow 用2-范数，内积 $(x, y) = \int_a^b x(t)y(t)dt$

一次多项式 $\Rightarrow M = \text{span}\{1, x\}$

解：方法一：

记 $\varphi_0(x) = 1$, $\varphi_1(x) = x$, 则 $(\varphi_i, \varphi_j) = \int_0^1 x^i x^j dx = \frac{1}{i+j+1}$ ($i, j = 0, 1$),

$$(f, \varphi_0) = \int_0^1 e^x dx = e - 1, \quad (f, \varphi_1) = \int_0^1 x e^x dx = 1,$$

故法方程为

$$\begin{bmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{3} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \end{bmatrix} = \begin{bmatrix} e-1 \\ 1 \end{bmatrix} \Rightarrow S^*(x) = 0.8731 + 1.6903x$$

例2 求 $[0,1]$ 上函数 $f(x) = e^x$ 的一次最佳平方逼近多项式。

方法二：将 $\{\varphi_1(x), \varphi_2(x)\} = \{1, x\}$ 规范正交化

$$\text{得 } \{e_1(x), e_2(x)\} = \{1, \sqrt{3}(2x-1)\}$$

$$\text{则法方程为 } \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} (f, e_1) \\ (f, e_2) \end{bmatrix} = \begin{bmatrix} e-1 \\ \sqrt{3}(3-e) \end{bmatrix}$$

$$\begin{aligned} \Rightarrow S^*(x) &= \alpha_1 e_1 + \alpha_2 e_2 = (e-1)e_1 + \sqrt{3}(3-e)e_2 \\ &= 0.8731 + 1.6903x \end{aligned}$$

若取最佳平方逼近空间 $M = \text{span}\{1, x, x^2, \dots, x^n\}$,

法方程系数矩阵为

$$H = \begin{bmatrix} 1 & \frac{1}{2} & \cdots & \frac{1}{n+1} \\ \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n+2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{n+1} & \frac{1}{n+2} & \cdots & \frac{1}{2n+1} \end{bmatrix} \quad \text{----- Hilbert 矩阵}$$

当 n 较大时其条件数很大,

用数值方法求解 $Hx = b$ 是不稳定的, 避免求解病态方程组!!

子空间中基的选取很重要

正交多项式：若多项式序列 $\{\varphi_i(x), x \in [a, b]\}_{i=0}^{\infty}$ 满足

$$(\varphi_j, \varphi_k) = \int_a^b \rho(x) \varphi_j(x) \varphi_k(x) dx = \begin{cases} 0, & j \neq k \\ A_k \neq 0, & j = k \end{cases} \quad (j, k = 0, 1, 2, \dots)$$

则称其为 $[a, b]$ 上带权 $\rho(x)$ 的正交系。

$\varphi_n(x)$ 是首项系数不为零的 n 次多项式。

3.3 勒让德多项式和切比雪夫多项式

为了避免求解病态方程组, 通常找 一组正交多项式。

常用的正交多项式有: 勒让德多项式, 切比雪夫多项式, 拉盖尔多项式, 埃尔米特多项式等, 这里只介绍最佳平方逼近中两种正交多项式:

1、勒让德 (Legendre) 多项式 (权为1)

2、切比雪夫 (Tchebichef) 多项式

3.3.1 勒让德多项式

勒让德多项式：区间 $[-1, 1]$ 上定义的多项式序列

$$P_n(x) = \frac{1}{2^n n!} \frac{d^n}{dx^n} [(x^2 - 1)^n] \quad (n = 0, 1, 2, \dots)$$

$$P_n(x) \text{ 的首项系数 } a_n = \frac{(2n)!}{2^n (n!)^2},$$

$$\text{从而 } \tilde{P}_0(x) = 1, \quad \tilde{P}_n(x) = \frac{n!}{(2n)!} \frac{d^n}{dx^n} [(x^2 - 1)^n], \quad (n = 1, 2, \dots)$$

是首项系数为1 的勒让德多项式。

勒让德多项式的性质：

(1) 正交性： **Legendre**多项式 $\{P_n(x)\}_{n=0}^{\infty}$ 在 $[-1,1]$ 上带权 $\rho(x)=1$ 正交

可推证： $(P_n, P_m) = \int_{-1}^1 P_n(x) P_m(x) dx = \begin{cases} \frac{2}{2n+1}, & m = n \\ 0, & m \neq n \end{cases} \quad (n, m = 0, 1, \dots)$

所以 $\left\{ \sqrt{\frac{2n+1}{2}} \cdot P_n(x) \right\} (n = 0, 1, 2, \dots)$ 是规范正交系。

(2) 奇偶性: $P_n(-x) = (-1)^n P_n(x)$,

n 为奇数时 $P_n(x)$ 是奇函数;

n 为偶数时 $P_n(x)$ 是偶函数。

(3) 递推关系:

$$\begin{cases} P_0(x) = 1 \\ P_1(x) = x \\ P_{n+1}(x) = \frac{2n+1}{n+1} x P_n(x) - \frac{n}{n+1} P_{n-1}(x), \quad (n = 1, 2, \text{L}) \end{cases}$$

由递推公式可得到低次**Legendre**多项式 $P_n(x)$ 的如下形式:

$$P_0(x) = 1$$

$$P_1(x) = x$$

$$P_2(x) = \frac{1}{2}(3x^2 - 1)$$

$$P_3(x) = \frac{1}{2}(5x^3 - 3x)$$

$$P_4(x) = \frac{1}{8}(35x^4 - 30x^2 + 3)$$

$$P_5(x) = \frac{1}{8}(63x^5 - 70x^3 + 15x)$$

...

例3 求 $[-1, 1]$ 上函数 $\sin \frac{\pi}{2} x$ 的三次最佳平方逼近多项式。

解：由于 $f(x) = \sin \frac{\pi}{2} x$ 是区间 $[-1, 1]$ 上的连续函数，

故取Legendre正交多项式作为基函数，

$$P_0(x)=1, P_1(x)=x, P_2(x)=\frac{1}{2}(3x^2-1), P_3(x)=\frac{1}{2}(5x^3-3x)$$

$$\text{因为 } (P_j, P_j) = \frac{2}{2j+1} \quad (j=0,1,2,3), \quad \underline{(f, P_0)} = \int_{-1}^1 \sin \frac{\pi x}{2} dx = 0$$

$$\underline{(f, P_1)} = \int_{-1}^1 x \sin \frac{\pi x}{2} dx = \frac{8}{\pi^2}, \quad \underline{(f, P_2)} = \int_{-1}^1 \frac{1}{2}(3x^2-1) \sin \frac{\pi x}{2} dx = 0$$

$$\underline{(f, P_3)} = \int_{-1}^1 \frac{1}{2}(5x^3-3x) \sin \frac{\pi x}{2} dx = \frac{48(\pi^2-10)}{\pi^4}$$

故法方程为

$$\begin{bmatrix} 2 & & & \\ & \frac{2}{3} & & \\ & & \frac{2}{5} & \\ & & & \frac{2}{7} \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \end{bmatrix} = \begin{bmatrix} 0 \\ \frac{8}{\pi^2} \\ 0 \\ \frac{48(\pi^2 - 10)}{\pi^4} \end{bmatrix}$$

解得: $\alpha_1=0, \alpha_2=\frac{12}{\pi^2}, \alpha_3=0, \alpha_4=\frac{168(\pi^2-10)}{\pi^4}$

求得 $f(x)$ 的三次最佳平方逼近多项式为

$$S(x) = \frac{12}{\pi^2}x + \frac{168(\pi^2-10)}{\pi^4} \cdot \frac{1}{2}(5x^3-3x) \approx 1.553191x - 0.562228x^3$$

法二： 取基函数 $\varphi_0(x)=1, \varphi_1(x)=x, \varphi_2(x)=x^2, \varphi_3(x)=x^3$,
构造法方程(四元线性方程组), 求解 $\alpha_i^* (i=0,1,2,3)$

计算量大
可能病态

例4 求 $[0,1]$ 上函数 $y = \arctan x$ 的一次最佳平方逼近多项式。

解：由于 $y = \arctan x \in C[0,1]$,

作代换 $x = \frac{1}{2}(t+1)$, $y = \arctan \frac{t+1}{2} \in C[-1,1]$.

取Legendre正交基 $P_0(t)=1$, $P_1(t)=t$,

计算得 $(P_0, P_0) = 2$, $(P_1, P_1) = \frac{2}{3}$, $\underline{(y, P_0)} = \int_{-1}^1 \arctan \frac{t+1}{2} dt = \frac{\pi}{2} - \ln 2$

$$\underline{(y, P_1)} = \int_{-1}^1 t \cdot \arctan \frac{t+1}{2} dt = \frac{\pi}{2} - 2 + \ln 2$$

故 $y = \arctan \frac{t+1}{2}$ 在 $[-1,1]$ 上的一次最佳平方逼近多项式为


$$y(t) = \left(\frac{\pi}{4} - \frac{1}{2} \ln 2\right) + \frac{3}{2} \left[\frac{\pi}{2} - 2 + \ln 2\right] \cdot t$$

$$\Rightarrow y \approx \left(\frac{\pi}{4} - \frac{1}{2} \ln 2\right) + \frac{3}{2} \left[\frac{\pi}{2} - 2 + \ln 2\right] (2x-1)$$

$y = \arctan x$ 在 $[0,1]$ 上一次最佳平方逼近多项式

一般地，求函数 $f(x)$ 在区间 $[a, b]$ 上的 n 次最佳平方逼近时，

$$\text{区间}[a, b] \xrightarrow{\text{变换}} [-1, 1] \quad \frac{b-x}{b-a} = \frac{1-t}{1-(-1)}$$



$$\Rightarrow x = \frac{b-a}{2}t + \frac{b+a}{2} \text{ (换元)}$$

$$f(x) = f\left(\frac{a+b}{2} + \frac{b-a}{2}t\right) \triangleq g(t)$$

求 $g(t)$ 在区间 $[-1, 1]$ 上的 n 次最佳平方逼近 $\xrightarrow{\text{代入 } t = \frac{2x}{b-a} + \frac{a+b}{a-b}}$ $f(x)$ 在区间 $[a, b]$ 上的 n 次最佳平方逼近

2.3.2 切比雪夫多项式

在 $[-1, 1]$ 上，带权函数 $\rho(x) = \frac{1}{\sqrt{1-x^2}}$ 正交的多项式族。

$$T_n(x) = \cos(n \arccos x), \quad -1 \leq x \leq 1$$

切比雪夫多项式的性质：

(1) $T_n(x)$ 是一个 n 次多项式，也可表示为如下递推关系

$$\begin{cases} T_0(x) = 1, T_1(x) = x, \\ T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x), \quad (n = 1, 2, \dots). \end{cases}$$

证明：显然 $n = 0$ 时, $T_0(x) = 1$

$$n = 1 \text{ 时, } T_1(x) = \cos(\arccos x) = x$$

令 $x = \cos \theta$, 则 $T_n(x) = \cos n\theta$ 。

$$\text{由于 } \cos(n+1)\theta = 2\cos n\theta \cos \theta - \cos(n-1)\theta \quad (n \geq 1)$$

$$\text{故 } T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x) \quad (n = 1, 2, \dots)$$

切比雪夫多项式的性质： $T_n(x) = \cos(n \arccos x)$, $-1 \leq x \leq 1$

$$\begin{cases} T_0(x) = 1, T_1(x) = x, \\ T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x), \quad (n = 1, 2, \dots) \end{cases}$$

由上述递推关系容易得到 $\{T_n(x)\}$ 如下：

$$T_0(x) = 1, \quad T_1(x) = x,$$

$$T_2(x) = 2x^2 - 1, \quad T_3(x) = 4x^3 - 3x,$$

$$T_4(x) = 8x^4 - 8x^2 + 1,$$

$$T_5(x) = 16x^5 - 20x^3 + 5x,$$

$$T_6(x) = 32x^6 - 48x^4 + 18x^2 - 1$$

..... $T_n(x)$ 的最高次项系数是 2^{n-1} ($n \geq 1$)

$\omega_n(x) = \frac{1}{2^{n-1}} T_n(x)$ 的最高次项系数是1

函数 $1, x, x^2, \dots, x^n$ 也可用 $T_0(x), T_1(x), \dots, T_n(x)$ 表示

$$1 = T_0(x), \quad x = T_1(x), \quad x^2 = \frac{1}{2}[T_0(x) + T_2(x)]$$

$$x^3 = \frac{1}{4}[3T_1(x) + T_3(x)]$$

$$x^4 = \frac{1}{8}[3T_0(x) + 4T_2(x) + T_4(x)]$$

$$x^5 = \frac{1}{16}[10T_1(x) + 5T_3(x) + T_5(x)]$$

$$x^6 = \frac{1}{32}[10T_0(x) + 15T_2(x) + 6T_4(x) + T_6(x)]$$

...

切比雪夫多项式的性质: $T_n(x) = \cos(n \arccos x)$, $-1 \leq x \leq 1$

(2) $T_n(x)$ 在 $[-1,1]$ 上带权函数 $\rho(x) = \frac{1}{\sqrt{1-x^2}}$ 正交,

并且 $(T_0, T_0) = \pi$, $(T_n, T_n) = \frac{\pi}{2}$ ($n \geq 1$)

证明: 令 $x = \cos \theta$, 则 $T_n(x) = \cos(n\theta)$, $0 \leq \theta \leq \pi$,

$$\begin{aligned}(T_n, T_m) &= \int_{-1}^1 \frac{T_n(x)T_m(x)}{\sqrt{1-x^2}} dx = \int_0^\pi \frac{\cos n\theta \cos m\theta}{\sin \theta} \sin \theta d\theta \\ &= \int_0^\pi \cos n\theta \cos m\theta d\theta = \begin{cases} 0, & n \neq m; \\ \pi / 2, & n = m \neq 0; \\ \pi, & n = m = 0. \end{cases}\end{aligned}$$

切比雪夫多项式的性质: $T_n(x) = \cos(n \arccos x)$, $-1 \leq x \leq 1$

(3) 奇偶性

$$\underline{T_n(-x)} = \cos(n \arccos(-x)) = \cos(n(\arccos x - \pi))$$

$$= \cos(n \arccos x - n\pi) = (-1)^n \cos(n \arccos x) = \underline{(-1)^n T_n(x)}$$

n 为奇数时 $T_n(-x) = -T_n(x)$ 是奇函数;

n 为偶数时 $T_n(-x) = T_n(x)$ 是偶函数。

例5 确定参数 a, b, c , 使得

$$I(a, b, c) = \int_{-1}^1 [\sqrt{1-x^2} - (ax^2 + bx + c)]^2 \frac{1}{\sqrt{1-x^2}} dx$$

取得最小值, 并计算最小值。

分析: 问题等价于求 $f(x) = \sqrt{1-x^2}$ 在 $[-1, 1]$ 上关于权函数 $\rho(x) = \frac{1}{\sqrt{1-x^2}}$ 的二次最佳平方逼近多项式 $P_2(x)$ 。

$$\begin{aligned} \text{而最小值即是平方误差 } \|\delta\|_2^2 &= \|f - P_2\|_2^2 \\ &= (f, f) - (f, P_2) \end{aligned}$$

例5 确定参数 a, b, c , 使得

$$I(a, b, c) = \int_{-1}^1 [\sqrt{1-x^2} - (ax^2 + bx + c)]^2 \frac{1}{\sqrt{1-x^2}} dx$$

取得最小值, 并计算最小值。

解法1: 选取切比雪夫基函数 $T_0 = 1, T_1 = x, T_2 = 2x^2 - 1$

求出

$$(T_0, T_0) = \pi, (T_1, T_1) = (T_2, T_2) = \frac{\pi}{2}$$

$$(f, T_0) = 2, (f, T_1) = 0, (f, T_2) = -\frac{2}{3}$$

法方程为

$$\begin{bmatrix} \pi & & \\ & \frac{\pi}{2} & \\ & & \frac{\pi}{2} \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \\ -\frac{2}{3} \end{bmatrix}$$

例5 确定参数 a, b, c , 使得

$$I(a, b, c) = \int_{-1}^1 [\sqrt{1-x^2} - (ax^2 + bx + c)]^2 \frac{1}{\sqrt{1-x^2}} dx$$

取得最小值, 并计算最小值。

$$\text{解得 } \alpha_1 = \frac{2}{\pi}, \alpha_2 = 0, \alpha_3 = -\frac{4}{3\pi}$$

故 $f(x)$ 的二次最佳平方逼近多项式为

$$P_2(x) = \sum_{j=0}^2 \frac{(T_j, f)}{(T_j, T_j)} T_j = \frac{2}{\pi} + 0 - \frac{4}{3\pi} (2x^2 - 1) = \frac{10}{3\pi} - \frac{8}{3\pi} x^2$$

$$\text{求出 } a = -\frac{8}{3\pi}, b = 0, c = \frac{10}{3\pi}. \text{ 误差 } I(a, b, c) = \|\delta\|_2^2 \approx 0.0146$$

综上: $a = -\frac{8}{3\pi}, b = 0, c = \frac{10}{3\pi}$ 时, $I(a, b, c)$ 取得最小值 $\frac{\pi}{2} - \frac{44}{9\pi}$

解法2: 选取基函数 $\varphi_0 = 1$, $\varphi_1 = x$, $\varphi_2 = x^2$, 则

$$(\varphi_0, \varphi_0) = \int_{-1}^1 \frac{1}{\sqrt{1-x^2}} dx = \pi \quad (\varphi_1, \varphi_1) = \int_{-1}^1 \frac{x^2}{\sqrt{1-x^2}} dx = \frac{\pi}{2}$$

$$(\varphi_0, \varphi_1) = \int_{-1}^1 \frac{x}{\sqrt{1-x^2}} dx = 0 \quad (\varphi_1, \varphi_2) = \int_{-1}^1 \frac{x^3}{\sqrt{1-x^2}} dx = 0$$

$$(\varphi_0, \varphi_2) = \int_{-1}^1 \frac{x^2}{\sqrt{1-x^2}} dx = \frac{\pi}{2} \quad (\varphi_2, \varphi_2) = \int_{-1}^1 \frac{x^4}{\sqrt{1-x^2}} dx = \frac{3\pi}{8}$$

$$(f, \varphi_0) = \int_{-1}^1 \sqrt{1-x^2} \frac{1}{\sqrt{1-x^2}} dx = 2,$$

$$(f, \varphi_1) = \int_{-1}^1 x \sqrt{1-x^2} \frac{1}{\sqrt{1-x^2}} dx = 0,$$

$$(f, \varphi_2) = \int_{-1}^1 x^2 \sqrt{1-x^2} \frac{1}{\sqrt{1-x^2}} dx = \frac{2}{3}$$

$$\text{由} \begin{bmatrix} \pi & 0 & \frac{\pi}{2} \\ 0 & \frac{\pi}{2} & 0 \\ \frac{\pi}{2} & 0 & \frac{3\pi}{8} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \\ \frac{2}{3} \end{bmatrix} \text{解得} \alpha_0 = \frac{10}{3\pi}, \alpha_1 = 0, \alpha_2 = -\frac{8}{3\pi}$$

$$P_2(x) = \frac{10}{3\pi} \cdot 1 + 0 \cdot x - \frac{8}{3\pi} \cdot x^2$$

$$\Rightarrow a = -\frac{8}{3\pi}, b = 0, c = \frac{10}{3\pi}$$

$$\text{而} I(a, b, c) = \|\delta\|_2^2 = \frac{\pi}{2} - \frac{44}{9\pi} \approx 0.0146$$

2.3.3 其它常用的正交多项式

1. 第二类切比雪夫多项式

在区间 $[-1,1]$ 上带权 $\rho(x) = \sqrt{1-x^2}$ 的正交多项式

$$U_n(x) = \frac{\sin[(n+1)\arccos x]}{\sqrt{1-x^2}}$$

$$\begin{aligned} \int_{-1}^1 U_n(x)U_m(x)\sqrt{1-x^2}dx &= \int_0^\pi \sin(n+1)\theta \sin(m+1)\theta d\theta \\ &= \begin{cases} 0, m \neq n \\ \frac{\pi}{2}, m = n \end{cases} \begin{cases} U_0(x) = 1, U_1(x) = 2x, \\ U_{n+1}(x) = 2xU_n(x) - U_{n-1}(x), \quad (n = 1, 2, \text{L}). \end{cases} \end{aligned}$$

2. 拉盖尔多项式

在区间 $[0, +\infty)$ 上带权 $\rho(x) = e^x$ 的正交多项式

$$L_n(x) = e^x \frac{d^n}{dx^n} (x^n e^{-x})$$

$$\int_0^{+\infty} L_n(x) L_m(x) e^{-x} dx = \begin{cases} 0, m \neq n \\ (n!)^2, m = n \end{cases}$$

$$\begin{cases} L_0(x) = 1, & L_1(x) = 1 - x \\ L_{n+1}(x) = (1 + 2n - x)L_n(x) - n^2 L_{n-1}(x), & (n = 1, 2, \dots) \end{cases}$$

3. 埃尔米特多项式

在区间 $(-\infty, +\infty)$ 上带权 $\rho(x) = e^{-x^2}$ 的正交多项式

$$H_n(x) = (-1)^n e^{x^2} \frac{d^n}{dx^n} (e^{-x^2})$$

$$\int_0^{+\infty} H_n(x) H_m(x) e^{-x^2} dx = \begin{cases} 0, m \neq n \\ 2^n n! \sqrt{\pi}, m = n \end{cases}$$


$$\begin{cases} H_0(x) = 1, & H_1(x) = 2x \\ H_{n+1}(x) = 2xH_n(x) - 2nH_{n-1}(x), & (n = 1, 2, \dots) \end{cases}$$

区间 $[a, b]$ 及权函数不同，得到的正交多项式也不同。

3.4 曲线拟合的最小二乘法

问题：已知数表 $(x_i, f(x_i))_{i=1 \sim n}$ ，希望用简单的函数 $y = S(x)$ 近似代替 $y = f(x)$ 。


1. 插值法：求出 $y = S(x)$ 使得 $S(x_i) = f(x_i)$ ， $i = 1 \sim n$ 。称 $y = S(x)$ 为函数 $y = f(x)$ 在点 x_1, x_2, \dots, x_n 处的插值函数。



缺点：通常已知数据有误差；在非节点处误差可能较大；
高次插值时计算量大

2 . 数据拟合法(离散情形的最佳平方逼近)

用近似函数 $y = S(x)$ 逼近函数 $y = f(x)$ 时,
不要求在节点处 $S(x_i) = f(x_i)$ ($i = 1 \sim n$),
只要求 $S(x)$ 能反映数据的基本变化规律,
使整体误差达到最小。常用的方法有:
最佳一致逼近法, **最小二乘法**等。




引 例1

已知热敏电阻数据：

温度 $t(^{\circ}\text{C})$	20.5	32.7	51.0	73.0	95.7
电阻 $R(\Omega)$	765	826	873	942	1032

求 60°C 时的电阻 R 。



根据数据描绘散点图，近似在一条直线上

故设 $S = a t + b$

a, b 为待定系数

由于 S 不一定是 t 的严格线性函数，而测量数据又有误差，所以无论怎样选取 a 和 b ，由公式计算的每一个测试点的 S 值都不可能恰好等于实测值 R_i 。

在现实问题中，通常选取的 a 和 b 应使得计算值 S 与实测值 R_i 之间的整体绝对误差最小

$$E_1 = \sum_{i=1}^7 |(a + bt_i) - R_i| \Leftrightarrow E_2 = \sum_{i=1}^7 [(a + bt_i) - R_i]^2$$

使 E_1 最小的 a 、 b 不容易计算，通常都要求 E_2 达到最小，由此求得的表示式称为 t_i 与 R_i 之间关系的一次最小二乘拟合或一次最小平方逼近。


引 例 2

已知一室模型快速静脉注射下的血药浓度数据($t=0$ 注射300mg)

t (h)	0.25	0.5	1	1.5	2	3	4	6	8
c ($\mu\text{g/ml}$)	19.21	18.15	15.36	14.10	12.89	9.32	7.45	5.24	3.01

求血药浓度随时间的变化规律 $c(t)$.

作半对数坐标系 (**semilogy**) 下的图形



根据数据描绘
散点图,

$$c(t) = c_0 e^{-kt}$$

c_0, k 为待定系数

最小二乘法

最小二乘法： 设 $\{\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)\}$ 是 $C[a, b]$ 空间中的 n 个

线性无关函数, $M = \text{span}\{\varphi_i\}_{i=0 \sim n}$, $S(x) = \sum_{i=0}^n \alpha_i \varphi_i(x) \in M$.

实验或测量得 $y = f(x)$ 的一组数 $(x_i, f(x_i))_{i=0 \sim m}$,

记 $\delta = \{\delta_i\}_{i=1 \sim n} = \{f(x_i) - S(x_i)\}$, 求 $S^*(x) = \sum_{i=1}^m \alpha_i^* \varphi_i(x) \in M$,

$$\text{s.t.} \quad \|\delta^*\|_2^2 = \sum_{i=1}^n [f(x_i) - S(x_i)]^2 = \min_{S(x) \in M} \sum_{i=1}^n [f(x_i) - S(x_i)]^2$$

$$\text{即} \quad \sum_{i=1}^n [f(x_i) - \sum_{j=1}^m \alpha_j^* \varphi_j(x_i)]^2 = \min_{\{\alpha_i\} \in K^m} \sum_{i=1}^n [f(x_i) - \sum_{j=1}^m \alpha_j \varphi_j(x_i)]^2$$

本质上为:

在空间 R^n 中,

子空间 $M = \text{span}\{\varphi_1, \varphi_2, \dots, \varphi_m\}$

内积为 $(y_1, y_2) = \sum_{i=1}^n y_1(i) y_2(i)$

范数为欧式范数 $\|y\|_2 = \sqrt{\sum_{i=1}^n y_i^2}$

求最佳逼近元。

例 6: 已知数据组

x_i	0.2	0.5	0.7	0.85	1
y_i	1.221	1.649	2.014	2.340	2.718

, 试用最小二乘法求 $f(x)$ 的二次近似多项式 $P_2(x) = a_1 + a_2x + a_3x^2$

解: $M = \text{span}\{1, x, x^2\} \triangleq \text{span}\{\varphi_0, \varphi_1, \varphi_2\}$, 则 $(\varphi_0, \varphi_0) = \sum_{i=1}^5 1 \times 1 = 5$,

$$(\varphi_1, \varphi_0) = \sum_{i=1}^5 x_i \times 1 = 3.250, \quad (\varphi_2, \varphi_0) = \sum_{i=1}^5 x_i^2 \times 1 = 2.503,$$

$$(\varphi_1, \varphi_1) = \sum_{i=1}^5 x_i \times x_i = 2.503, \quad (\varphi_2, \varphi_1) = \sum_{i=1}^5 x_i^2 \times x_i = 2.090,$$

$$(\varphi_2, \varphi_2) = \sum_{i=1}^5 x_i^2 \times x_i^2 = 1.826, \quad (f, \varphi_0) = \sum_{i=1}^5 y_i \times 1 = 9.942,$$

$$(f, \varphi_1) = \sum_{i=1}^5 y_i \times x_i = 7.185, \quad (f, \varphi_2) = \sum_{i=1}^5 y_i \times x_i^2 = 5.857,$$

例 6: 已知数据组

x_i	0.2	0.5	0.7	0.85	1
y_i	1.221	1.649	2.014	2.340	2.718


, 试用最小二乘法求 $f(x)$ 的二次近似多项式 $P_2(x) = a_1 + a_2x + a_3x^2$, 并估计误差。

$$\text{法方程} \begin{bmatrix} 5 & 3.250 & 2.503 \\ 3.250 & 2.503 & 2.090 \\ 2.503 & 2.090 & 1.826 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 9.942 \\ 7.185 \\ 5.857 \end{bmatrix}.$$

$$\Rightarrow a_0 = 1.036, \quad a_1 = 0.751, \quad a_2 = 0.928.$$

$$\Rightarrow P_2(x) = 1.036 + 0.751x + 0.928x^2$$

$$P_2(x) = 1.036 + 0.751x + 0.928x^2$$



$$\text{均方误差} \|\delta\|_2 = \sqrt{\sum_{i=1}^5 [f(x_i) - s^*(x_i)]^2} \approx 0.0086$$

$$\text{最大值误差} \|\delta\|_\infty = \max_{1 \leq i \leq 5} |f(x_i) - s^*(x_i)| \approx 0.0055$$

加权的最小二乘拟合问题

为了反映某些测试点在所研究问题中所占的比重，
通常用加权的误差标准来衡量最佳逼近问题.

R^n 中带权 $w_i \geq 0$ ($i = 1, 2, \dots, n$) 的内积和范数

$$(x, y) = \sum_{i=1}^n w_i x_i y_i, \quad \|x\|_2 = \sqrt{\sum_{i=1}^n w_i x_i^2}$$

例如 w_i 可表示在 $(x_i, f(x_i))$ 处重复观测的次数

加权的最小二乘拟合问题

设 $\{\varphi_i(x)\}_{i=0}^n$ 是 $C[a,b]$ 中 $n+1$ 个线性无关函数, $M = \text{span}\{\varphi_i\}_{i=0}^n$

已知 $f(x)$ 在 m 个相异点的样本值 $\{f(x_i)\}_{i=1}^m$,

$$\text{求 } s^*(x) = \sum_{j=0}^n \alpha_j^* \varphi_j(x) \in M,$$

$f(x)$ 在点 x_i 处的权

$$\text{使得 } \sum_{i=1}^m w(x_i) [f(x_i) - s^*(x_i)]^2 = \min_{s(x) \in M} \sum_{i=1}^m w(x_i) [f(x_i) - s(x)]^2$$

称 $s^*(x)$ 为 $f(x)$ 在 M 中的加权最小二乘拟合函数,

求 $s^*(x)$ 的方法称为加权的最小二乘法。

加权的最小二乘拟合问题

$$\text{法方程} \begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_n, \varphi_n) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix} = \begin{bmatrix} (f, \varphi_0) \\ (f, \varphi_1) \\ \vdots \\ (f, \varphi_n) \end{bmatrix}$$


$$\Rightarrow (\alpha_0^*, \dots, \alpha_n^*) \quad \Rightarrow s^*(x) = \sum_{j=0}^n \alpha_j^* \varphi_j(x)$$

$$\text{均方误差} \|\delta\|_2 = \sqrt{\sum_{i=1}^m w(x_i) [f(x_i) - s^*(x_i)]^2}$$

例7：测得铜导线在温度 T_i 时的电阻 R_i ，求电阻 R 与温度 T 的关系

i	1	2	3	4	5	6	7
T_i	19.1	25.0	30.1	36.0	40.0	45.1	50.0
R_i	76.30	77.80	79.25	80.80	82.35	83.90	85.10

$$\varphi_0=1, \varphi_1=T$$



取各点的权

$$w_i = \frac{1}{7} \quad (i = 1, 2, \dots, 7)$$

例7：测得铜导线在温度 T_i 时的电阻 R_i ，求电阻 R 与温度 T 的关系

i	1	2	3	4	5	6	7
T_i	19.1	25.0	30.1	36.0	40.0	45.1	50.0
R_i	76.30	77.80	79.25	80.80	82.35	83.90	85.10

解： $\varphi_0=1, \varphi_1=T$ 权 $w_i=\frac{1}{7} (i=1,2,\dots,7)$

$$(\varphi_0, \varphi_0) = \frac{1}{7} \sum_{i=1}^7 1 \times 1 = 1, \quad (\varphi_1, \varphi_0) = \frac{1}{7} \sum_{i=1}^7 T_i \times 1 = \frac{245.3}{7}, \quad (\varphi_1, \varphi_1) = \frac{1}{7} \sum_{i=1}^7 T_i \times T_i = \frac{9325.83}{7},$$

$$(R, \varphi_0) = \frac{1}{7} \sum_{i=1}^7 R_i = \frac{566.5}{7}, \quad (R, \varphi_1) = \frac{1}{7} \sum_{i=1}^7 R_i \times T_i = \frac{20029.445}{7}$$

$$\text{法方程} \begin{cases} 7a + 245.3b = 566.5 \\ 245.3a + 9325.83b = 20029.445 \end{cases} \Rightarrow R \approx 70.572 + 0.291T$$

用最小二乘法解决**实际问题**的过程包含四个步骤：

- (1) 由观测数据表中的数值点，画出未知函数的粗略图形——散点图；
- (2) 从散点图中确定拟合函数类型 Φ ；
- (3) 通过最小二乘原理，确定拟合函数 $\varphi(x) \in \Phi$ 中的未知参数；
- (4) 通过实验进行验证。

拟合曲线的选择

- 专业知识和经验
- 离散点图的分布形状及特点
- 反复计算比较误差
- 现有的自动选择数学模型的程序

避免病态问题

- 离散数据拟合实质上是连续函数子空间上的极值问题。最小二乘法是计算机数据处理的重要方法，被广泛采用。
- 当 m 较大时，法方程组是病态的。提高拟合多项式的次数不一定能改善逼近效果。
- 实际计算中常采用不同的低次多项式去拟合不同的分段，称为分段拟合。

避免病态问题

如果 $\{\varphi_i(x)\}_{i=0}^n$ 关于采样点 $\{x_i\} (i=0,1,\dots,m)$ 带权 $w(x_i) (i=0,1,\dots,m)$ 正交, 即

$$(\varphi_j, \varphi_k) = \sum_{i=0}^m w(x_i) \varphi_j(x_i) \varphi_k(x_i) = \begin{cases} 0, & j \neq k \\ A_k > 0, & j = k \end{cases}$$

$$a_k^* = \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)} = \frac{\sum_{i=0}^m w(x_i) f(x_i) \varphi_k(x_i)}{\sum_{i=0}^m w(x_i) \varphi_k^2(x_i)} \quad (k=0,1,\dots,n)$$

$$\|\delta\|_2 = \|f - s^*\|_2 = \sqrt{\|f\|_2^2 - \sum_{k=0}^n w_k (a_k^*)^2}$$

带权的首项系数为1的正交多项式构造

$$P_0(x), P_1(x), \dots, P_n(x) (n \leq m)$$

$$\begin{cases} P_0(x) = 1, \\ P_1(x) = (x - \alpha_1)P_0(x), \\ P_{k+1}(x) = (x - \alpha_{k+1})P_k(x) - \beta_k P_{k-1}(x) \quad (k = 1, 2, \dots, n-1). \end{cases}$$

$$\begin{cases} \alpha_{k+1} = \frac{\sum_{i=0}^m w(x_i) x_i P_k^2(x_i)}{\sum_{i=0}^m w(x_i) P_k^2(x_i)} = \frac{(xP_k, P_k)}{(P_k, P_k)}, \\ \beta_k = \frac{\sum_{i=0}^m w(x_i) P_k^2(x_i)}{\sum_{i=0}^m w(x_i) P_{k-1}^2(x_i)} = \frac{(P_k, P_k)}{(P_{k-1}, P_{k-1})} \end{cases} \quad (k = 0, 1, \dots, n-1)$$

避免病态问题

$$M = \text{span} \{P_0(x), P_1(x), \dots, P_n(x)\}$$

$$s^*(x) = \sum_{k=0}^n \alpha_k^* P_k(x)$$

$$\alpha_k^* = \frac{(f, P_k)}{(P_k, P_k)} = \frac{\sum_{i=0}^m w(x_i) f(x_i) P_k(x_i)}{\sum_{i=0}^m w(x_i) P_k^2(x_i)}$$

构造正交多项式（复杂）；法方程求解简单